Proyecto de Pipeline y análisis de datos

Autor: Mauricio Montes
Fecha: 13-jul-2025

Descripción del dataset

El dataset consiste en un registro de tickets de vuelos en India. Eso significa que los viajes son entre ciudades importantes de India, y el precio de los vuelos está calculado en *rupias indias*. El objetivo del dataset es entrenar un modelo predictivo con regresión lineal, pero fue utilizado para este proyecto.

El dataset fue obtenido en Kaggle, a través del siguiente enlace:

- Kaggle: Kaggle: Flight Price Prediction

Limpieza y transformación del dataset

El dataset ya estaba limpio a la hora de cargarlo, así que no fue necesario hacer mucho. Igualmente, se llamaron a funciones para hacer una limpieza sencilla, eliminando registros con valores nulos y repetidos.

```
# Limpieza básica
df.drop_duplicates();
df.dropna();
```

Para el análisis de datos, habían columnas que no fueron utilizadas. La columna eliminada fue `flight`, pues era el código de viaje; aunque había otra columna molesta relacionada a los índices del dataset, que también fue eliminada: `Unnamed: 0`.

```
# Eliminando columnas innecesarias
df.drop(columns=['flight', 'Unnamed: 0'], inplace=True);
```

La nueva columna agregada, que tenía como objetivo verificar si había una correlación significativa con el precio, fue la columna `route`, que concatena la ciudad de salida y de llegada.

```
# Nueva columna
df['route'] = df['source_city'] + ' to ' + df['destination_city']
```

Por último, se verificó varias veces que tener a las clases de vuelo Economy y Business unidas afectaba a verificar la correlación. Esto principalmente porque la variación de precios entre estas clases era enorme. Es por ello que es más útil visualizar los datos segmentados por la clase del ticket.

```
# Segmentación por clase de vuelo
df_economy = df[df['class'] == 'Economy']
df_business = df[df['class'] != 'Economy']
```

Capturas de las visualizaciones

Mapa de calor

El mapa de calor compara la correlación de las variables numéricas de los dataset segmentados. Se ignoran los casos con correlación igual a uno; pues es la comparación con la misma variable.

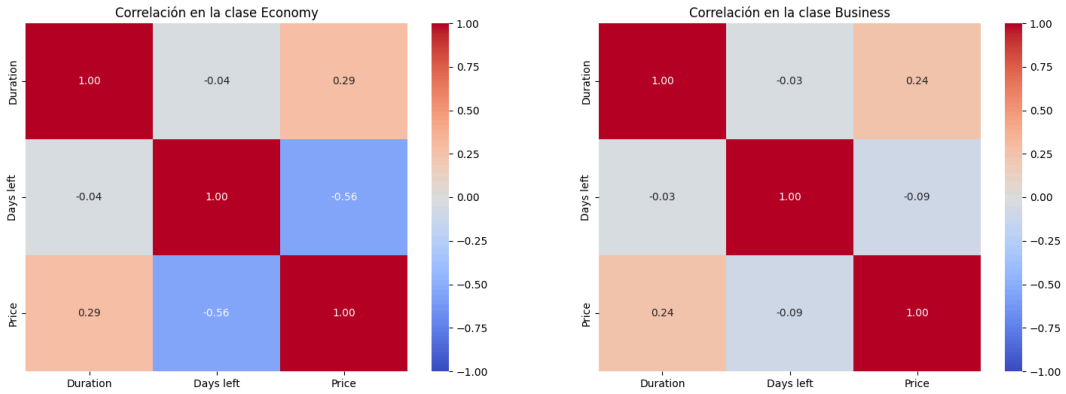
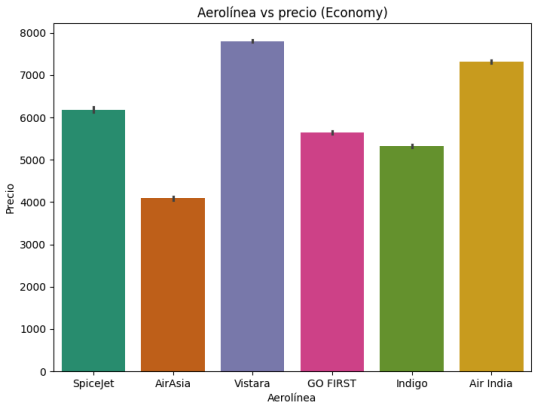
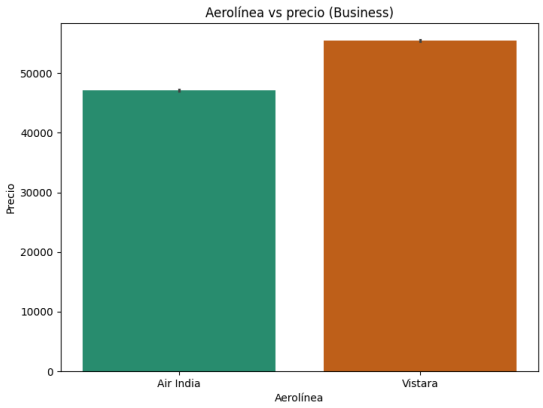


Gráfico de barras

El gráfico de barras quiere comparar si hay una influencia significativa en el precio a causa de la aerolínea encargada del viaje. Es interesante observar que, de todas las aerolíneas, solo dos tienen vuelos en clase Business.





Conclusiones fundamentales

La principal conclusión es en la correlación del precio con la clase del vuelo. El precio depende inmensamente de la clase: La media del precio clase Business es casi diez veces la media de la clase Economy. Incluso aún, la influencia es tan grande que obstaculiza verificar la correlación con el resto de la clases.

También, hay una correlación débil entre la cantidad de días restantes para el vuelo y el precio: Entre más días faltan para un vuelo, más barato resulta ser generalmente. Esta correlación se observa más en la clase Economy, con una correlación de 0.56 negativo (pues es una correlación decreciente).
Sin embargo, esta correlación no es visible en la clase Business; aunque puede que esto se vea influenciado en el hecho de que la clase Economy tiene mayor variación de precios a causa de las aerolíneas, mientras que Business solo tiene dos aerolíneas que proveen dicho servicio.

En la clase Economy, el gráfico de barras muestra que la aerolínea "Vistara" es la aerolínea más cara, junto con la aerolínea "Air India" como la segunda más costosa; lo cual es interesante, considerando que estas son las únicas aerolíneas que figuran en el gráfico de barras de la clase Business.
Esto puede significar que estas aerolíneas por sí mismas son aerolíneas de lujo o que ofrecen un mejor servicio en general que el resto de aerolíneas.

La duración del viaje en horas también parece influir un poco en el precio del vuelo. Como se puede observar en el mapa de calor, la correlación es baja, de alrededor del 0.2; pero hay que considerar que hay otras variables en juego que pueden alterar la visualización de la correlación.

Una última conclusión es que la cantidad de paradas también influye en el precio, aunque es difícil de determinar dada la desviación estándar. Parece ser que los viajes con una para son más costoso que los viajes con varias paradas; y significativamente más costosos que los viajes directos.
Esto puede ser a causa de que los viajes son locales, no internacionales.