Creación de clases básicas y manipulación de datos con Python.

Autor: Mauricio Montes
Fecha: 15 jun 2025

Documentación

Esta documentación es acerca del módulo de Python `data_preprocessor.py`, para poder utilizarlo bien y sin problemas. El código utiliza anotaciones y convenciones de tipeo establecidas por Pyright para mayor robustez y estructura del código (y porque demasiada libertad me abruma).

Dependencias

El módulo requiere a la librería `pandas` para funcionar en primer lugar, pues depende fuertemente de esta para sus procesos.

DataPreprocessor

```
class DataPreprocessor
```

La clase `DataPreprocessor` es una clase por medio de la cual se pretende simplificar el proceso de limpiado de datos dentro de objeto `DataFrame` de la librería `pandas`. Usando esta clase es posible cargar datos, hacer una limpieza sencilla, y exportarlos en archivos .csv utilizando los métodos dados por `pandas`.

Constructor

```
DataPreprocessor()
```

Atributos

`pandas.DataFrame | None`	`dataframe`: Contiene los datos cargados con los que trabajar.

Funciones públicas

Retorno	Descripción

`None`	`cargar_datos(`
	`path: str,`
	`separator: str | None,`
	`start_row: int | None`
	`)`
	
	Carga los datos de un archivo .csv en `dataframe`.

`None`	`limpiar_datos()` Elimina registros duplicados y registros con valores nulos. Los cambios se guardan en `dataframe`
`None`	`exportar_datos(path: str)` Exporta un archivo .csv con los datos guardados en `dataframe`

DataAnalyzer

```
class DataAnalyzer(DataPreprocessor)
```

Con esta clase se pueden hacer análisis sencillos sobre un conjunto de datos del tipo `DataFrame` de la librería `pandas`.

Constructor

```
DataAnalyzer()
```

Funciones públicas

Retorno	Descripción
`pandas.DataFrame`	`resumen()` Devuelve los valores máximos y mínimos, y medias de las series numéricas dentro de un conjunto de datos.

Atributos heredados

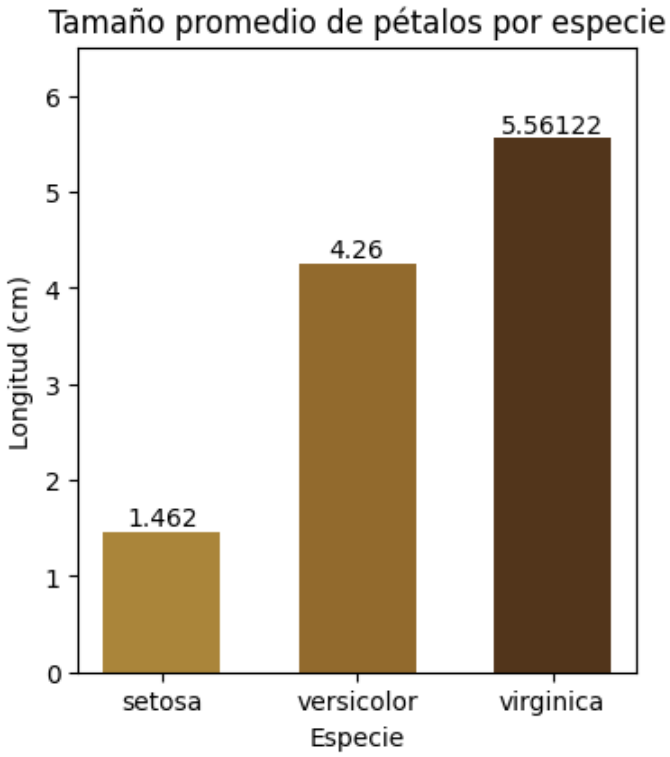
- `<DataPreprocessor>.dataframe`

Funciones heredadas

- `<DataPreprocessor>.cargar_datos`
- `<DataPreprocessor>.limpiar_datos`

- `<DataPreprocessor>.exportar_datos`

Visualización de datos



Pregunta a responder

> ¿Por qué es importante eliminar datos duplicados en un análisis de datos?

Diría que es porque afecta mucho a los cálculos estadísticos, pues estos toman en cuenta el número de datos en sus cálculos. Si hay muchos datos duplicados, la cantidad aumenta, pero la información que proveen no lo hace, por lo que hay redundancia.

Aunque, hay ocasiones en las que los datos parecen ser duplicados, pero no lo son; supongo que depende del contexto de los datos, como puede ser un registro de ventas (pero que por algún motivo no tiene fechas de ventas).